ANALYSE DE DONNEES TRAVAUX DIRIGES 2

Aminata FALL

2024-08-02

CHARGEMENT DES LIBRARIES

```
library("FactoMineR")
library(factoextra)
```

CHARGEMENT DU JEU DE DONNEES DECATHLON

```
data(decathlon)
```

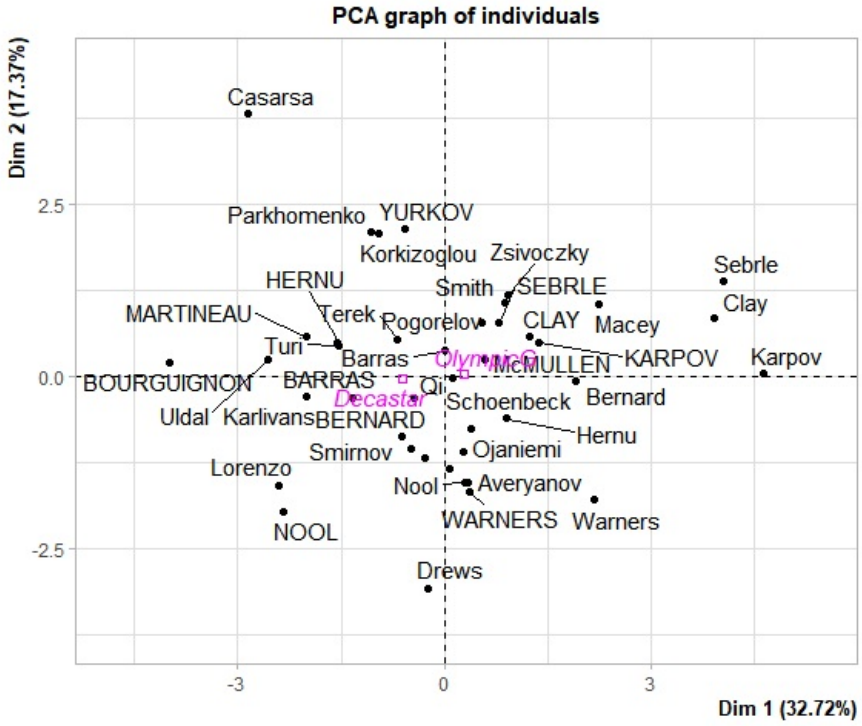
IDENTIFICATION ET AFFICHAGE DE DONNEES ACTIVES

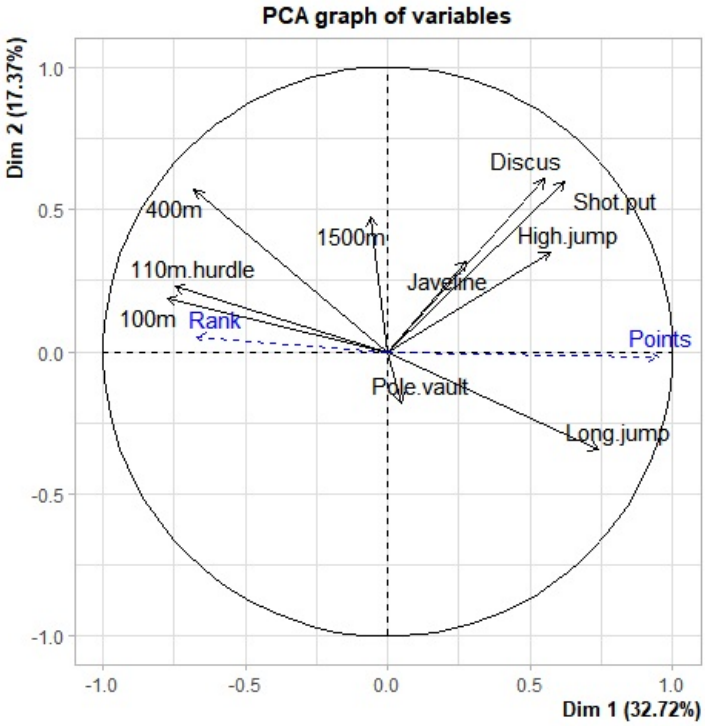
```
decathlon_active=decathlon[1:23,1:6]
head(decathlon_active)
```

```
##          100m Long.jump Shot.put High.jump  400m 110m.hurdle
## SEBRLE  11.04      7.58    14.83      2.07 49.81       14.69
## CLAY    10.76      7.40    14.26      1.86 49.37       14.05
## KARPOV  11.02      7.30    14.77      2.04 48.37       14.09
## BERNARD 11.02      7.23    14.25      1.92 48.93       14.99
## YURKOV  11.34      7.09    15.19      2.10 50.42       15.31
## WARNERS 11.11      7.60    14.31      1.98 48.68       14.23
```

Les données actives sont les données quantitatives qui permettront de réaliser l'ACP.

REALISATION DE L'ACP AVEC LES VARIABLES ET INDIVIDUS ILLUSTRATIVES





En plus de variables qui appartiennent aux colonees de 1 à 6, les colonnes de 7 à 10 sont aussi des variables quantitaives qu'il serait interessant d'inclure dans la réalisation de l'ACP. En essayant de faire l'ACP sur les 6 premières colonnes (data_active) R ne m'a pas donné de résultat donc j'ai considéré toutes les colonnes de la base de données sauf les variables 11 et 12 comme données quantitatives supplémentaires et la colonne 13 comme variable qualitative supplémentaire.

Dans le graphe, des individus nous constatons une répartion des athlètes par rapport à l'évènement auquel il ont compéti: Decastar ou OlympicG. Dans le graphe des variables,nous avons un cercle de corrélation entre les disciplines et le nombre de points obtenus mais également la corrélation entre les disciplines et le rang de l'athlète.

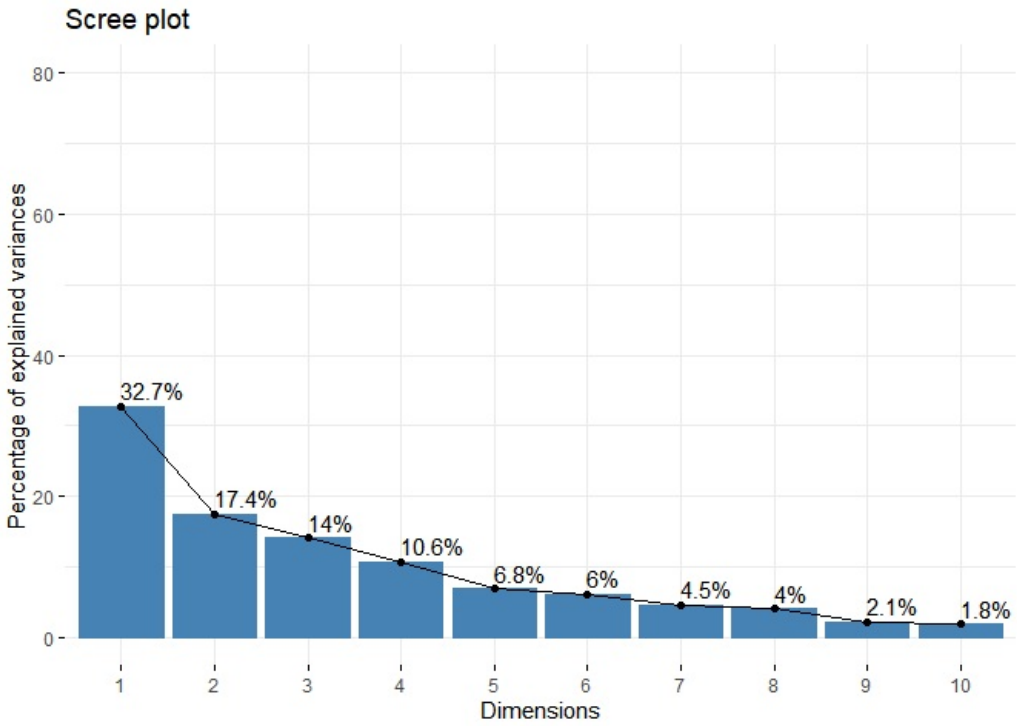
AFFICHAGE DES VALEURS PROPRES

```
eig_val=get_eigenvalue(res_acp1)
eig_val
```

```
##        eigenvalue variance.percent cumulative.variance.percent
## Dim.1   3.2719055        32.719055                    32.71906
## Dim.2   1.7371310        17.371310                    50.09037
## Dim.3   1.4049167        14.049167                    64.13953
## Dim.4   1.0568504        10.568504                    74.70804
## Dim.5   0.6847735         6.847735                    81.55577
## Dim.6   0.5992687         5.992687                    87.54846
## Dim.7   0.4512353         4.512353                    92.06081
## Dim.8   0.3968766         3.968766                    96.02958
## Dim.9   0.2148149         2.148149                    98.17773
## Dim.10  0.1822275         1.822275                   100.00000
```

L'output nous donne 10 dimensions avec leur valeur propre respectives, la pourcentage de variance expliquée et le pourcentage de variance cumule.

REPRESENTATION DES VALEURS PROPRES



Interprétation:

Le graphique donne le pourcentage de variation expiquée en fonction des composantes principales. Le premier axe principal contient 32% de la variation des données.La porion de variance expliquée diminue au fur et à mesure avec chaque axe. Le deuxième axe donne 17% de la variabilité. Les deux premières composantes principales donnent en cumul une explication de 50% des informations contenues sur les données.En ajoutant un troixième composantes on arrive à retenir 64% de l'information.

RESULTAT DE L'ACP SUR LES VARIABLES ACTIVES

```
res_acp=PCA(decathlon_active,graph=FALSE,)
print(res_acp)
```

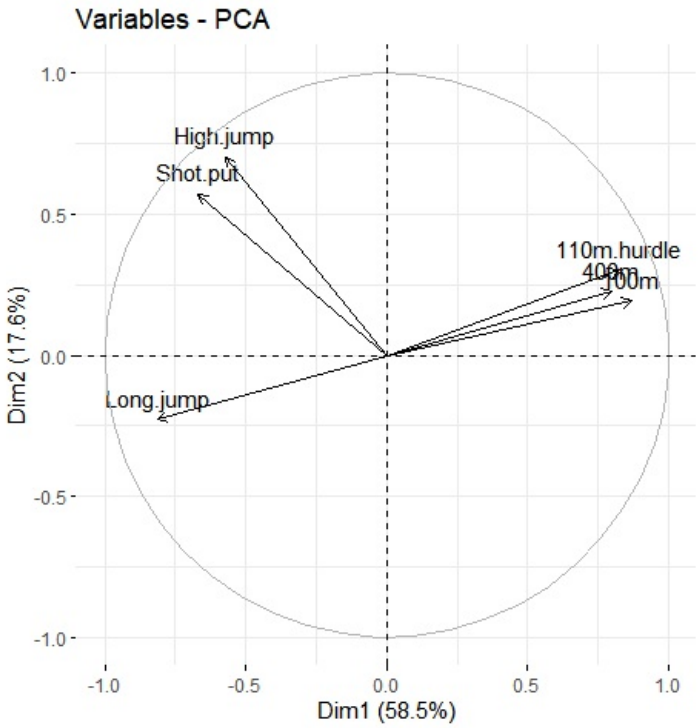
```
## **Results for the Principal Component Analysis (PCA)**
## The analysis was performed on 23 individuals, described by 6 variables
## *The results are available in the following objects:
##
##    name               description
```

```
## 1  "$eig"             "eigenvalues"
## 2  "$var"             "results for the variables"
## 3  "$var$coord"       "coord. for the variables"
## 4  "$var$cor"         "correlations variables - dimensions"
## 5  "$var$cos2"        "cos2 for the variables"
## 6  "$var$contrib"     "contributions of the variables"
## 7  "$ind"             "results for the individuals"
## 8  "$ind$coord"       "coord. for the individuals"
## 9  "$ind$cos2"        "cos2 for the individuals"
## 10 "$ind$contrib"     "contributions of the individuals"
## 11 "$call"            "summary statistics"
## 12 "$call$centre"     "mean of the variables"
## 13 "$call$ecart.type" "standard error of the variables"
## 14 "$call$row.w"      "weights for the individuals"
## 15 "$call$col.w"      "weights for the variables"
```

COMBIEN DE COMPOSANTES PRINCIPALES CHOISIR:

En utilisant la règle du coude, on trouve une proportion totale de variance expliquée de 50% avec les deux premières composantes.Donc on choisit les deux premières composantes principales.

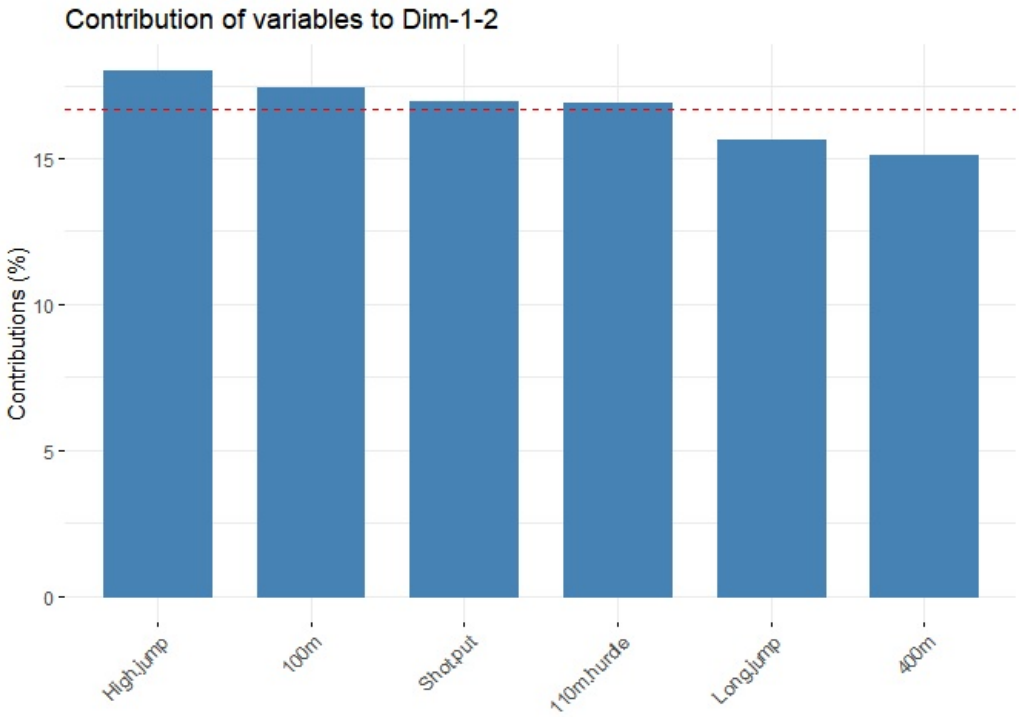
CERCLE DE CORRELATION DES VARIABLES



Interprétation:

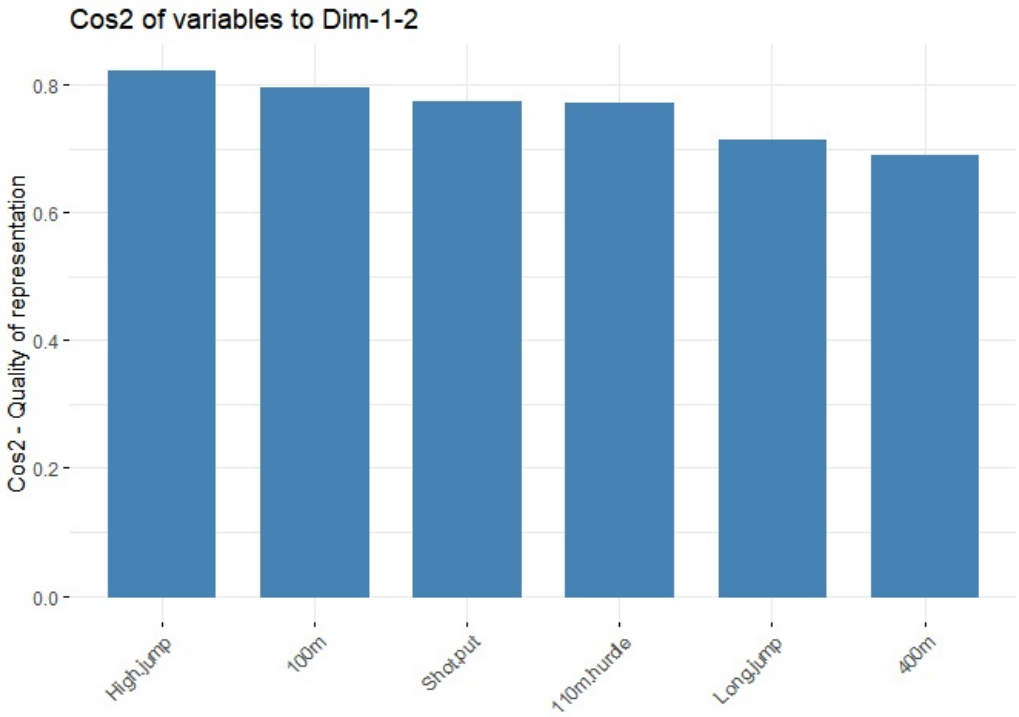
Les variables qui sont les mieux représentés dans le cercle de corrélation sont: Shotput, High jump, 400m, Hurdle, 100m et Long jump. Les disciplines qui sont positivement corrélés entre eux sont : le Shotput, high jump et long jump. Le long jump est négativement corrélé avec le 100m, 110m hurdle et le 400m, cependant ils sont tous bien représentés sur la dimension 2(dim2). Le shotput et le high jump sont bien représentés sur les deux dimensions.

REPRESENTATION DE LA CONTRIBUTION DES VARIABLES



Les variables qui ont le plus contribuées à la formation de ces deux axes sont: le high jump et le 100m. Le Shotput et le 110m hurdle ont un contribution qui dépasse tout juste la moyenne.

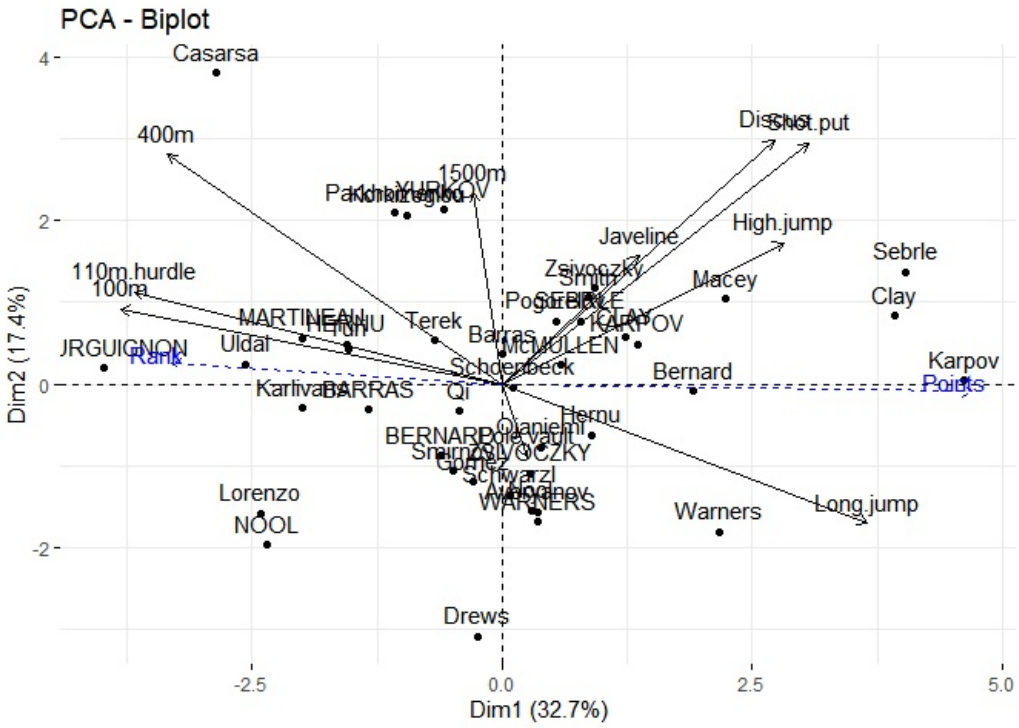
QUALITE DE REPRESENTATION DES VARIABLES SUR LES DEUX PREMIERS AXES



Interprétation:

Toutes les variables du graphique sont bien représentées dans les dimensions 1 et 2. Il ont tous un cosinus carré supérieur à 0,5.

GRAPHE DES INDIVIDUS ET VARIABLES ILLUSTRATIVES



Interprétation:

On remarque que les individus tel que Serble, Clay et Karpov ont marqué le plus de points. Ils sont bon en High Jump, Long jump et Shot put qui sont des disciplines positivement correlées entre elles.Donc un individus qui a une bonne performance dans l'une de ces disciplines a tendance à être bon dans l'autre aussi. Le high jump, long jump et le shotput sont aussi les discplines qui donnent le plus de points aux athlètes et par conséquent ils ont aussi un bon rang dans la competition. Bourguiguon par exemple qui est bien en 110m hurdel et 100m est moins bien classé. Il sera moins bon dans les disciplines qui sont négativement corrélées avec 110m Hurdle et le 100m comme le long Jump. On remarque aussi un outlier, Carsarsa qui ne s'est pas démarqué dans une discipline particulière. Ses performances ne ressemblent pas à ceux des autres groupes d'athlètes.